Nozeli 文件引擎中文样例文档

唯一标记 PDF：多页可选中文本校验句。

本 PDF 由 tools/make-samples.py 调用 Google Chrome 无头模式生成，目的是验证 PDF.js 文本层能否逐字抽取中文内容。页面共三页，每一页都包含可被选中的文字。

下面的表格用于确认表格单元格中的中文与数字都能被独立抽取，且不会与相邻 单元格粘连。

序号	部件	说明
1	文本层	必须可被逐字抽取
2	表格	三列结构保持稳定
3	页码	共三页，连续编号

第一组：编号句子

1. 第一句编号：文件引擎在只读模式下返回原始字节，不做任何隐式转码。
2. 第二句编号：适配器层负责把相对路径解析成宿主可以接受的绝对路径。
3. 第三句编号：所有写入操作都必须落在原型目录之内，越界访问一律拒绝。
4. 第四句编号：sidecar 文件名由内容哈希推导，因此天然幂等。
5. 第五句编号：视图模型只描述结构，不携带任何宿主相关的渲染指令。
6. 第六句编号：文本层抽取的结果应当与源文档逐字一致。

第二组：编号句子

7. 第七句编号：哈希比对可以让回归测试直接定位到发生变化的字节区间。
8. 第八句编号：浏览器宿主通过 HTTP 访问文件接口，Electron 宿主走 IPC。
9. 第九句编号：两种宿主的接口形状必须完全同构，否则核心层会分叉。
10. 第十句编号：中文标点、数字 0123456789 与拉丁字母混排时不得错位。
11. 第十一句编号：容量单位 1.5 GiB 与百分比 87.5% 均应保持原样。
12. 第十二句编号：这一句用于确认列表编号不会污染正文抽取结果。

补充段落

最后一段用于确认长段落在页面底部的换行与断字行为。当一行的长度接近版面宽度 时，文本层仍然应当按阅读顺序输出字符，而不是按绘制顺序打乱。这里再补充一些 中英文混排内容：The engine returns bytes, 引擎返回字节，二者必须完全一致。

第三页同时包含一个短代码块，用于确认等宽字体的抽取不会插入多余空白。

```
readSidecar("samples/pdf/nozeli-sample.zh.pdf") -> {"pages": 3}
```

唯一标记 PDF 结语：文本层抽取到此结束。